

# Consignes de projet AI28 – Machine Learning

Mokhtar Z. Alaya et Salim Bouzebda

Printemps 2026

## 1 Groupes

(Groupe 1) BADINGA-BOUEYESSA Benie, KAMDEM KAMDEM Berulle

(Groupe 2) BOURGEOIS Téo, CARRÉ Valentin

(Groupe 3) BOUZID Bouchra, H'MIDA Meïssa

(Groupe 4) CASSAN Pierre-Lo, LEZAIRE Solène

(Groupe 5) CHAPLET-DURET Armand, NDEYE Aminata Aida Faye

(Groupe 6) CLAUSE Pierrick, MAROS Enzo

(Groupe 7) DERBALI Sofian, REMMACHE Yanis

(Groupe 8) DJAHNIT Yanis, MEZEMATE Ahlem

(Groupe 9) FALLOUH Thomas, LOPEZ-VILESPY Etienne

(Groupe 10) GODIN Noé, TEA Steven

(Groupe 11) JOUGLA Maxime, ZEHREN William

(Groupe 12) LE GOFF Mathis, VERCELLONI Léonard

(Groupe 13) LÉZÉAN Mathis, ZAL Jean-Maxime

## 2 Projet

Le projet doit être effectué en binôme. Il consiste à traiter un problème de machine learning avec un jeu de données réelles, dont nous vous fournirons les éléments nécessaires. Il faut réaliser une démarche méthodologique de machine learning de bout en bout, permettant de répondre au problème posé, à l'aide des algorithmes étudiés dans le cours. Justifiez les choix de méthode, de paramètres, etc.; liez les résultats des éventuelles analyses préalables des algorithmes.

### 3 Rapport

Le rapport doit inclure une présentation claire et concise du problème et des données, une définition de l'objectif de l'étude, la démarche choisie et les résultats obtenus, ainsi qu'une conclusion, sans dépasser **10 pages au format PDF** en utilisant le template LaTeX fourni. D'éventuelles illustrations complémentaires, non essentielles à la compréhension du travail, pourront être mises dans des annexes (appendices).

Le rapport (obligatoirement en PDF), accompagné du code source (un Jupyter notebook (et/ou un script Python) qui a servi à générer les résultats présentés dans le rapport) devra être archivé dans un seul fichier .ZIP et déposé sur Moodle dans l'activité "Dépôt Projets AI28-P26" avant **Samedi 21/06/2024 à 23h59**.

Chaque figure devra comporter une légende expliquant ce qui est illustré. Attention, une pénalité sera appliquée si une figure n'est pas reproductible.

### 4 Template LaTeX

Vous allez utiliser le template LaTeX de la conférence *International Conference on Learning Representations 2024*, téléchargeable à l'adresse : <https://github.com/ICLR/Master-Template/raw/master/iclr2026.zip>. Il est très simple d'éditer ce template : titre, noms de chaque trinôme, sections, importation des figures et tableaux, conclusion, etc. Pour ne pas effectuer une installation de MikeTeX<sup>1</sup> (sous Windows) ou MacTeX<sup>2</sup> (sous macOS), nous vous conseillons de créer un compte sur PLMlatex<sup>3</sup> et de charger le template LaTeX ICLR sur PLMlatex. Un lien sera généré que vous pourrez partager, ainsi chaque membre du groupe pourra contribuer à la rédaction du rapport.

### 5 Soutenance

Une séance de soutenance des projets aura lieu durant la semaine des examens. Les soutenances dureront 15 minutes pour chaque trinôme et permettront de vérifier que chaque étudiant.e est bien auteur.e de son projet.

### 6 Distribution de projets

Nous vous proposons **8 projets** avec des jeux de données réelles répertoriés sur le site web UCI Machine Learning Repository<sup>4</sup>. La liste des titres des projets sera mise en ligne dans l'espace Moodle à partir du **mercredi 4 juin**. En cliquant sur le titre d'un projet, vous serez redirigés vers sa page de description ainsi que les données qui l'accompagnent.

Chaque projet peut être traité **au plus par deux groupes**. Une fois que les membres d'un groupe se mettent d'accord pour le choix d'un projet, vous devez me contacter par e-mail pour son attribution. Attention ! Nous appliquons la règle "FIFO (First In First Out)", premier arrivé, premier servi.

---

<sup>1</sup><https://miktex.org>

<sup>2</sup><https://tug.org/mactex/>

<sup>3</sup><https://plmlatex.math.cnrs.fr//>

<sup>4</sup><https://archive.ics.uci.edu/ml/index.php>

Un fichier Excel **Groupes et distribution de données** dans la section de Projets est mis à jour régulièrement pour les projets affectés aux groupes. Avant de m’envoyer votre e-mail, vous devez consulter ce fichier pour savoir si le sujet que vous allez choisir est encore disponible.

## 7 Points d’évaluation

### 7.1 Rapport

Le rapport doit contenir une présentation claire et concise du problème et des données, une définition de l’objectif de l’étude, la démarche choisie et les interprétations des résultats obtenus. Vous devez développer les principales étapes pour le projet de machine learning de bout en bout :

- Description succincte du projet à inclure dans l’abstract (voir template).
- Analyse exploratoire des données.
- Prétraitement des données.
- Modélisation : un large panel de modèles prédictifs doit figurer dans votre rapport.
- Optimisation : précisez les fonctions objectives utilisées et les algorithmes pour leur optimisation.
- Hyper-optimisation des paramètres des modèles (validation croisée, GridSearchCV, ...). Vous devez utiliser une librairie d’hyper-optimisation comme : `optuna`<sup>5</sup>, `SHERPA`<sup>6</sup>, `Hyperopt`<sup>7</sup>, ou toute autre bibliothèque de votre choix.
- Évaluation des performances des modèles et comparaison.
- Votre recommandation de modèle(s) pour le problème étudié.

**La présentation des résultats et leurs interprétations sont des points forts pour l’évaluation.**

### 7.2 Code

Nous vous encourageons à écrire un code “pythonique”, c’est-à-dire un code Python bien conçu et documenté pour faciliter sa compréhension. En particulier, vous pouvez coder des petites fonctions avec des pipelines de prétraitement, de modélisation, d’évaluation, ... pour automatiser le plus possible l’exécution de vos programmes.

---

<sup>5</sup><https://optuna.org>

<sup>6</sup><https://parameter-sherpa.readthedocs.io/en/latest/>

<sup>7</sup><http://hyperopt.github.io/hyperopt/>